一、论文信息

- **标题**：DYNAMIXSFT: Dynamic Mixture Optimization of Instruction Tuning Collections
- **作者**：Haebin Shin、Lei Ji、Xiao Liu、Zhiwei Yu、Hyunwoo Yoo、Qi Chen、Yeyun Gong（Haebin Shin 在微软研究院实习期间完成此工作）
- **机构**：密歇根大学、微软研究院、韩国科学技术院（KAIST AI）、北京智源人工智能研究院（BAAI）、德雷塞尔大学
- **发表会议和时间**：Findings of ACL 2026，2026 年 7 月
- **本地论文链接**：DYNAMIXSFT 论文 PDF
- **研究问题**：如何在大语言模型指令微调过程中，以较低的额外计算开销，根据模型不断变化的学习需求动态调整不同数据集的采样比例，同时保留原始数据集合的多样性与覆盖度?
- **一句话总结**：DYNAMIXSFT 将数据集混合建模为多臂老虎机问题，利用一步前瞻损失下降奖励评估各数据集当前的学习价值，并通过先验缩放的玻尔兹曼探索动态调整采样比例，在兼顾原始数据分布与持续探索的同时提升指令微调效果。
- **关键词**：大语言模型、指令微调、动态数据混合、多臂老虎机、先验缩放玻尔兹曼探索、一步前瞻奖励

二、Motivation

- **静态配比不够灵活**：不同数据组合和训练顺序会影响模型能力，固定配比难以适应模型随训练变化的学习需求。
- **已有动态方法成本较高**：往往依赖额外模型（MOS,HBO）、验证集（DDS）或昂贵的梯度计算，需要更轻量的动态调整方法。
- **动态采样需兼顾覆盖度**：只追逐高奖励数据可能导致采样过度集中，需要在提高学习收益的同时保留数据多样性。

核心动机：以较低的额外开销，根据模型当前的学习进展动态优化数据配比，同时兼顾多样性与覆盖度。

三、动态数据混合优化（Dynamic Mixture Optimization）

3.1 将数据混合建模为多臂老虎机问题

将从K个候选数据集中采样最优训练批次（Batch）的问题，建模为**多臂老虎机问题**，动作选择策略采用**玻尔兹曼探索策略**。

> 补充：多臂老虎机问题及其在本文中的对应 ›

什么是多臂老虎机（Multi-Armed Bandit, MAB）？
想象面前有多台老虎机，每台的收益事先未知。我们需要反复选择一台尝试，根据获得的奖励调整后续选择，目标是最大化长期累计收益。关键是在**利用**（选择已知收益较高的机器）与**探索**（尝试其他机器，发现更好的选择）之间取得平衡。

在本文中的对应关系：

MAB 概念	在 DYNAMIXSFT 中的对应
臂	一个候选数据集 D_k，共 K 个
选择动作	按概率选择数据集，再从该数据集中均匀抽取样本，逐个组成训练 Batch
奖励	在该数据集一个小批次上进行虚拟一步更新，损失的相对下降幅度，用于估计当前学习价值
价值估计 Q_k	对该数据集历史奖励进行指数移动平均（EMA），得到平滑的收益估计
策略 p_k	选择各数据集的概率，即动态调整的数据混合比例

这里，**利用**意味着提高当前学习收益较高的数据集的采样概率；**探索**意味着仍给其他数据集保留采样机会，避免长期忽略它们。

与经典的固定收益场景不同，模型在不断学习，**同一数据集的收益也会随训练状态变化**，因此本文面对的是非平稳的 MAB 场景。算法会定期评估所有数据集的奖励并更新采样概率，而不是一次确定配比后保持不变。

采样概率改造过程 ›

典型的玻尔兹曼探索通过以下 Softmax 函数计算采样概率：

$$p_k = \frac{\exp(\beta Q_k)}{\sum_j \exp(\beta Q_j)} \tag{1}$$

这种方式将不同数据集的奖励值 Q 视为可以直接进行比较的量，可能导致采样分布过度偏向某些特定数据集，而忽略这些数据集合自身的固有特征。

在监督微调阶段，训练样本的**多样性与覆盖范围都至关重要。** 作者假设原始数据集的比例（通常根据数据集大小确定）能够隐含地反映每个数据集的固有特征。

为此，作者提出了**先验比例缩放的玻尔兹曼探索**，将原始数据集分布 $p^{(0)}$ 显式引入，作为先验信息，将公式（1）扩展为：

$$p_k = \frac{\exp(\beta Q_k)\, p_k^{(0)}}{\sum_j \exp(\beta Q_j)\, p_j^{(0)}} \tag{2}$$

这种引入先验比例的采样策略，使学习得到的采样分布受到**原始数据集比例的软约束。** 因此，该策略既能够根据奖励反馈自适应地更新采样概率，又能够保留原始数据混合方案所具有的广泛覆盖性和多样性。

然而，由于奖励具有非平稳性，仍然可能出现某些数据集**采样概率过低、长期无法被采样**的问题。为缓解这一问题，作者引入**最小采样概率下界** γ/K，确保每个数据集都具有至少 γ/K 的采样概率。这保证了对所有数据集进行一定程度的均匀探索，并使采样策略能够适应奖励分布的突然变化。

最终，多臂老虎机的采样概率定义为公式（3）：

$$\boxed{p_k = (1-\gamma)\frac{\exp(\beta Q_k)\, p_k^{(0)}}{\sum_j \exp(\beta Q_j)\, p_j^{(0)}} + \frac{\gamma}{K}} \tag{3}$$

其中：

- **锐度系数** β：控制先验比例缩放的玻尔兹曼项的利用强度。
- **均匀性系数** γ：通过 γ/K 项保证一定程度的探索。

两者共同实现探索与利用之间的有效平衡。

算法 1：DYNAMIXSFT（中文伪代码）

输入

- 数据：数据集集合 $\mathcal{C} = \{D_1, \ldots, D_K\}$、先验概率 $p^{(0)}$、EMA 价值 $Q \in \mathbb{R}^K$。
- 策略参数：锐度系数 β、均匀性系数 γ、EMA 平滑系数 α。
- 训练参数：总步数 T、奖励更新间隔 T_{update}、批次大小 B。

---

1. **初始化**：对所有数据集，令 $Q_k \leftarrow 0$。
2. **对于训练步 $t = 1, \ldots, T$，执行：**

   ① 构造训练批次：令 $B_t \leftarrow \varnothing$；当 $|B_t| < B$ 时，重复：

   - 计算各数据集的采样概率：

$$p_k \leftarrow (1-\gamma)\frac{\exp(\beta Q_k)\, p_k^{(0)}}{\sum_j \exp(\beta Q_j)\, p_j^{(0)}} + \frac{\gamma}{K}$$

     # 奖励驱动选择，先验维持覆盖，下界保证探索。
   - 按 p 选择数据集 D，再从 D 中均匀采样一个样本 x。
   - 加入批次：$B_t \leftarrow B_t \cup \{x\}$。

     # 逐个抽样，同一个 Batch 可包含多个数据集的样本。

   ② 正式训练：使用批次 B_t 更新模型参数。

   ③ 定期更新奖励：若 $t \bmod T_{\text{update}} = 0$，则对每个数据集 $D_k \in \mathcal{C}$：
   - 从 D_k 中采样奖励评估批次 B_{D_k}。
   - 计算一步前瞻奖励：

$$r_k \leftarrow \frac{1}{|B_{D_k}|} \sum_{x \in B_{D_k}} \frac{\mathcal{L}_{\text{pre}}(x) - \mathcal{L}_{\text{post}}(x)}{\mathcal{L}_{\text{pre}}(x) + \epsilon}$$

     # 比较虚拟一步更新前后的相对损失下降，不保留虚拟更新的参数改动。
   - 更新 EMA 价值：

$$Q_k \leftarrow \alpha Q_k + (1-\alpha) r_k$$

     # 平滑奖励波动，更新后的价值用于后续采样。
3. **结束训练循环。**

3.2 单步前瞻奖励

目标：为那些预计能够更有效地促进模型**当前训练进展**的数据集分配更高的采样概率。

具体来说，在每个更新间隔 T_{update}，通过计算**单步前瞻损失变化来估计各数据集的贡献。**
对于每个数据集，首先使用一个小批次的数据，对模型进行一次临时的梯度更新，然后测量模型的 Loss 因此次更新而下降了多少。

对于数据集 D_i，其奖励计算方式如下：

$$\boxed{r_{D_i} \leftarrow \frac{1}{|B_{D_i}|} \sum_{x \in B_{D_i}} \frac{\mathcal{L}_{\text{pre}}(x) - \mathcal{L}_{\text{post}}(x)}{\mathcal{L}_{\text{pre}}(x) + \epsilon}} \tag{4}$$

其中： $\mathcal{L}_{\text{pre}}(x)$ 和 $\mathcal{L}_{\text{post}}(x)$ 分别表示执行一次虚拟梯度更新前后的 Loss。

为了缓解不同数据集之间的奖励尺度差异，以及偶尔出现的负奖励问题，使用 **Min-Max 归一化** 对各数据集的奖励进行归一化处理。

$$\tilde{r}_i = \frac{r_i - r_{\min}}{r_{\max} - r_{\min}}$$

这种轻量级的前瞻奖励机制，使多臂老虎机调度器能够动态优先选择那些**单位成本下能够带来更大即时 Loss 下降的数据源**。

为了减轻奖励的随机波动，并适应训练奖励固有的非平稳性，对每个数据集的奖励维护一个**指数移动平均**：

$$\boxed{Q_{D_i} \leftarrow \alpha Q_{D_i} + (1 - \alpha) r_{D_i}} \tag{5}$$

四、借鉴意义

1：不一定需要像MOS,HBO一样额外训练策略网络，计算开销问题（本文的计算开销：定期评估各数据集的奖励，实际开销取决于奖励计算成本、数据集数量和更新频率。）
值得研究：更复杂的策略网络带来的性能提升，是否足以抵消额外计算成本？
2：提供奖励函数设计方法：单步前瞻奖励