本笔记仅记录在MOS上拓展的部分

一、论文信息

- **标题**：HBO: Hierarchical Balancing Optimization for Fine-Tuning Large Language Models
- **作者**：Weixuan Wang、Minghao Wu、Barry Haddow、Alexandra Birch（前两位为共同第一作者）
- **机构**：爱丁堡大学信息学院、阿里巴巴通义实验室
- **发表会议和时间**：ICLR 2026，2026 年 4 月
- **本地论文链接**：论文pdf/HBO.pdf
- **研究问题**：如何在大语言模型微调过程中，同时应对不同数据集之间及单个数据集内部的数据不平衡与异质性？
- **一句话总结**：HBO在MOS基础上拓展了局部策略网络，利用全局与局部 Actor，根据模型训练状态动态调整数据集之间及数据集内部不同难度组的采样比例，从而提升微调效果。
- **关键词**：大语言模型、监督微调、层次化动态采样、数据平衡、双层优化、REINFORCE

二、Motivation

MoS 等方法主要调整**不同数据集之间的采样比例**，但未显式处理**单个数据集内部的差异**：即使来自同一数据源，样本的难度、质量等特征也可能不同，仅调整数据集间配比仍不够。

因此，HBO 希望同时优化两个层面的数据使用：

- **全局层面**：不同数据集之间如何分配训练机会。
- **局部层面**：单个数据集内部，不同难度的样本如何分配训练机会。

由于人工联合设计两级配比需要大量调试与计算，论文进一步提出：**能否让模型根据自身训练状态，自主调整全局与局部的数据采样策略？**

三、分层均衡优化（Hierarchical Balancing Optimization）

HBO 在 MoS 的数据集级动态配比基础上，进一步引入数据集内部的采样策略，联合优化大语言模型参数 θ 与两类策略网络：

- **全局策略网络（Global Actor）** ψ_{global}：调整不同数据集之间的采样概率，分配各数据集获得的训练机会。

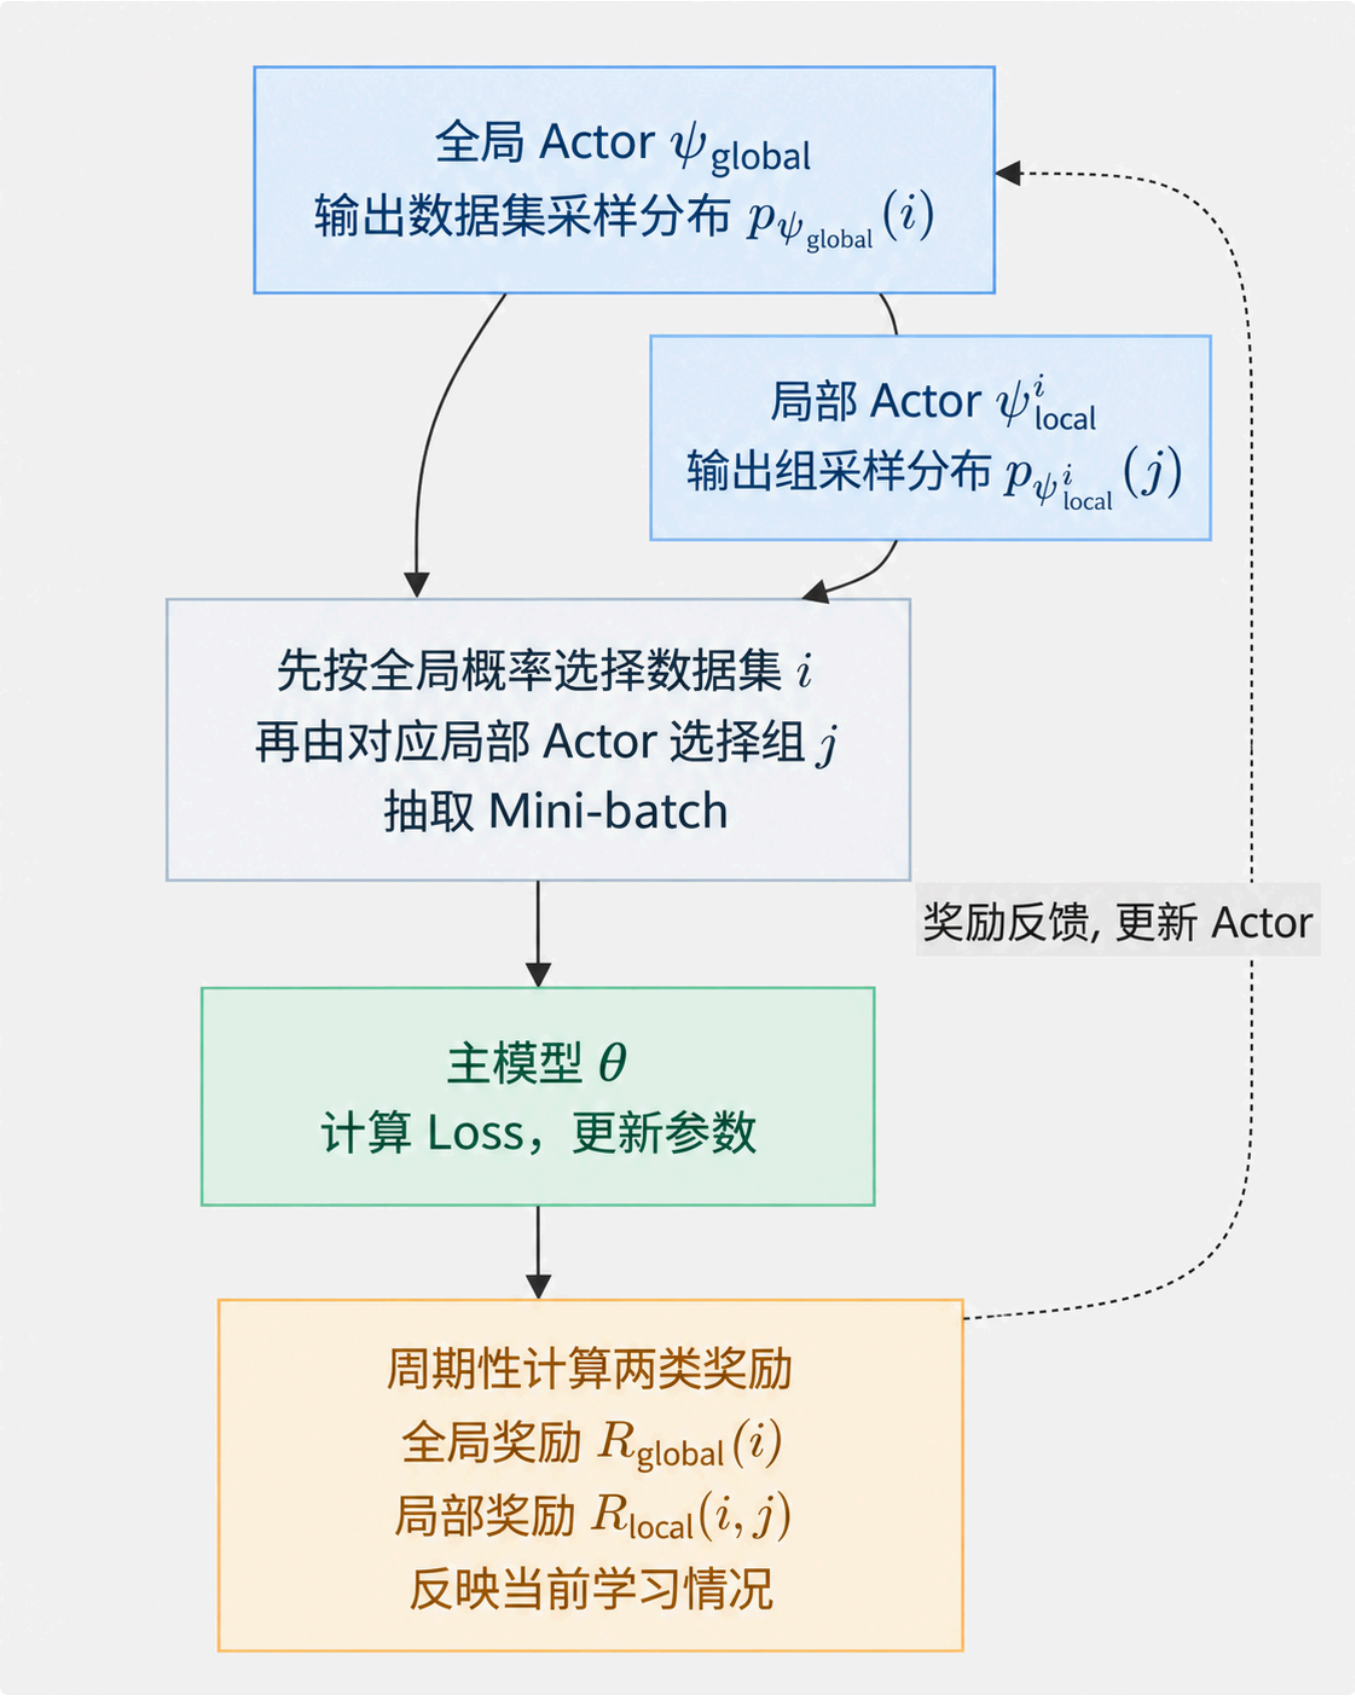
- **局部策略网络（Local Actor）** ψ^i_{local}：调整第 i 个数据集内部不同难度组的采样概率，处理数据集内部的异质性。

其中，ψ_{local} 表示所有局部策略网络的集合，每个数据集对应一个局部策略网络。

与 MoS 一样，**大语言模型 θ 与训练数据集 D 共同构成环境（Environment）**；不同之处在于，HBO 使用全局与局部两类 Actor 作为智能体（Agents），共同决定训练数据的采样分布。

3.1 双层优化问题

相较于 MoS 仅优化数据集间的采样分布，HBO 将模型训练中的采样过程扩展为两级：**先选择数据集，再选择该数据集内部的难度组**。


全局 Actor ψ_{global}
输出数据集采样分布 $p_{\psi_{\text{global}}}(i)$
局部 Actor ψ^i_{local}
输出组采样分布 $p_{\psi^i_{\text{local}}}(j)$
先按全局概率选择数据集 i
再由对应局部 Actor 选择组 j
抽取 Mini-batch
奖励反馈，更新 Actor
主模型 θ
计算 Loss，更新参数
周期性计算两类奖励
全局奖励 $R_{\text{global}}(i)$
局部奖励 $R_{\text{local}}(i,j)$
反映当前学习情况

其双层优化目标为：

$$
\boxed{
\begin{aligned}
(\psi_{\text{global}}, \psi_{\text{local}}) &= \arg \min_{\psi_{\text{global}}, \psi_{\text{local}}} \mathcal{J}(D; \theta(\psi_{\text{global}}, \psi_{\text{local}}))\,, \\
\theta(\psi_{\text{global}}, \psi_{\text{local}}) &= \arg \min_{\theta} \mathbb{E}_{i \sim p_{\psi_{\text{global}}}(N)} \left[\mathbb{E}_{j \sim p_{\psi^i_{\text{local}}}(M_i)} \left[\mathcal{L}\big((x^{i,j}, y^{i,j}); \theta\big) \right] \right].
\end{aligned}
} \tag{5}
$$

3.2 HBO 算法实现

算法 1：分层均衡优化（HBO）

输入：$D = \left\{ \left\{ \{(x_k^{i,j}, y_k^{i,j})\}_{k=1}^{Q_{i,j}} \right\}_{j=1}^{M_i} \right\}_{i=1}^{N}$；

N 个数据集，第 i 个数据集包含 M_i 个组；

第 j 个组包含 $Q_{i,j}$ 对指令 $x_k^{i,j}$ 与响应 $y_k^{i,j}$；

$F_{\text{global}}, \gamma_{\text{global}}$：全局 Actor 的更新间隔与学习率；

$F_{\text{local}}, \gamma_{\text{local}}$：局部 Actor 的更新间隔与学习率；

T：总训练步数；　α：主模型 θ 的学习率。

输出：收敛后的主模型 θ。

按公式（3）初始化全局与各局部采样分布，令 $\tau = 1$；

各层按对应数据量比例初始化

对于 $t = 0$ 到 T，执行：

| $\tilde{i} \sim p_{\psi_{\text{global}}}(N)$；　# 先选择数据集

| $\tilde{j} \sim p_{\psi^{\tilde{i}}_{\text{local}}}(M_{\tilde{i}})$；　# 再选择该数据集内的组

| 抽取批次 $(x, y) \sim D^{\tilde{i},\tilde{j}}$；　# 整个批次来自选中的组

| $\theta \leftarrow \theta - \alpha \cdot \nabla_\theta \mathcal{L}(y \mid x; \theta)$；　# 更新主模型

| **若 $t \bmod F_{\text{global}} = 0$，则：**　# 周期性更新全局策略

| | **对于 $i = 1$ 到 N，执行：**

| | | $(x', y') \sim D^i$；　# 从每个数据集抽取奖励评估批次

| | | 按论文第 3.3 节计算 $\mathcal{R}_{\text{global}}(i)$；　# 评价数据集的学习需求

| | **结束循环**

| | $\psi_{\text{global}} \leftarrow \psi_{\text{global}} + \sum_{i=1}^{N} \gamma_{\text{global}} \cdot \mathcal{R}_{\text{global}}(i) \cdot \nabla_{\psi_{\text{global}}} \log p_{\psi_{\text{global}}}(i)$；

| | # REINFORCE 调整数据集之间的采样概率

| **结束条件分支**

| **若 $t \bmod F_{\text{local}} = 0$，则：**　# 周期性更新局部策略

| | **对于 $i = 1$ 到 N，执行：**　# 遍历各数据集

| | | **对于 $j = 1$ 到 M_i，执行：**　# 遍历该数据集的各组

| | | | $(x', y') \sim D^{i,j}$；　# 从每组抽取奖励评估批次

| | | | 按论文第 3.3 节计算 $\mathcal{R}_{\text{local}}(i, j)$；　# 评价该组的相对学习进度

| | | **结束循环**

| | | $\psi^i_{\text{local}} \leftarrow \psi^i_{\text{local}} + \sum_{j=1}^{M_i} \gamma_{\text{local}} \cdot \mathcal{R}_{\text{local}}(i, j) \cdot \nabla_{\psi^i_{\text{local}}} \log p_{\psi^i_{\text{local}}}(j)$；

| | | # REINFORCE 调整该数据集内各组的采样概率

| | **结束循环**

| **结束条件分支**

结束循环

注：第 20 行显式使用 ψ^i_{local}，表示只更新第 i 个数据集对应的局部 Actor；$p_{\psi^i_{\text{local}}}(j)$ 表示在已选定数据集 i 的条件下选择第 j 个组的概率。

在 HBO 中，全局策略网络和局部策略网络均采用两层全连接神经网络实现。

3.3 奖励函数

全局奖励：
近期研究表明，随着模型逐渐完成学习，梯度的 L_2 范数通常会减小（Chen et al., 2018）。

$$\boxed{\mathcal{R}_{\text{global}}(i) = \|\nabla_\theta \mathcal{L}(B_i;\theta)\|_2} \tag{7}$$

以数据集 i 中随机批次 B_i 的梯度 L2 范数作为奖励，优先为梯度范数较大、被视为仍有较大学习空间的数据集分配训练机会。

局部奖励：

$$\boxed{\mathcal{R}_{\text{local}}(i,j) = \frac{1}{K}\sum_{k=1}^{K}\frac{\text{PPL}(y_k^{i,j};x_k^{i,j},\theta)}{\text{PPL}(y_k^{i,j};x_k^{i,j},\theta_0)}} \tag{8}$$

沿用 MoS 的相对困惑度奖励，对数据集 i 的第 j 组中抽取的 K 个样本计算当前模型 θ 与初始模型 θ_0 的 PPL 比值并取平均，比值越高表示相对学习进展越小，因而获得更高的采样优先级。

四、实验简洁结论

- 分层优化有效：全局与局部策略网络均能独立提升性能，联合使用效果更好。
- 难度分组需要平衡粒度与学习效果：4 组在本文实验中取得最佳整体性能，但不能据此认为其他任务也以 4 组最优。
- 初始分布鲁棒性较强：相比 MoS，HBO 对不同初始采样分布的敏感性更低。
- 数据规模适应性较好：在不同训练数据比例下，HBO 均取得比 MoS 更大的性能提升。
- 简单样本不可忽视：仅保留困难样本并不一定有利于训练，保留不同难度的数据有助于提升整体性能。