MoS 动态数据配比：L2 奖励替换、概率修正及五轮离线验证完整总结

研究平台：DiffusionDrive + nuScenes | 方法：MoS（Mixture of Skills） | 整理截至 2026 年 11 月 9 日

一、实验背景与总体研究路线

本阶段研究从将 MoS 原有奖励替换为 L2 改善量开始，逐步经历：

L2-MoS 首次训练
评估奖励替换后的驾驶指标

⇓

五域采样概率校正
解决 Actor 目标与实际帧曝光不一致

⇓

奖励与 Actor 机制修正
修改优化目标、轮换奖励样本并完成训练

⇓

五轮离线验证
序列级优化 → 误差容忍 → 单段限幅 → 平滑与余量 → 双侧域约束

⇓

确定两个正式训练候选
尚未开始新候选的正式训练

1. 数据与训练设置

项目	设置
基础模型	DiffusionDrive
数据集	nuScenes
领域划分	SENNA 五域
领域类别	低速/停驻、转向/换道、加速、减速、直行保持
序列数量	1400 条
序列长度	13～18 帧
总训练帧数	23930 帧
混域序列	657 条
Actor 更新间隔	每 200 次模型参数更新
奖励目标数量	每域 64 个，共 320 个
参数更新配置	两个微步，每微步四卡合计 24 帧，即每次更新 48 帧

五个领域的原始自然占比：

领域	原始占比
低速/停驻	22.26%
转向/换道	6.89%
加速	0.90%
减速	1.19%
直行保持	68.75%

二、阶段一：L2-MoS 首次训练与问题排查

1. 首次实验结果

将 MoS 奖励替换为 L2 改善量，与原始 MoS 及五域 DiffusionDrive 基线对照。

指标	五域基线	原始 MoS	L2-MoS
L2↓(m)	**0.5746**	0.6089	0.6010
碰撞率↓	0.0754%	0.1172%	**0.0586%**
PDMS↑	88.5763	**88.7599**	88.5037

实验时间：训练 9 小时 02 分；原记录标注评测完成于 11 月 9 日 09:03。

2. 发现的问题：域采样概率与实际训练曝光比例不一致

MoS 的 Actor 输出五个域的采样概率，但 DiffusionDrive 按完整连续序列采样，部分序列包含多个域。

- 采样器按照序列顺序逐帧读取。
- 每帧作为当前输入时，均参与训练 Loss 计算（受有效掩码约束）。
- 例如一段序列包含 6 帧直行、4 帧转向，完整消费后产生 6 次直行曝光和 4 次转向曝光。

因此，**Actor 输出的域采样概率不一定等于实际训练帧的域曝光比例。**

在 L2-MoS 中，转向域出现了明确偏差：

转向域统计	比例
Actor 输出	10.57%
采样映射预期	8.16%
实际训练曝光	8.13%

Actor 目标与实际曝光相差 **2.44 个百分点**，而映射预期与实际仅差 0.03 个百分点。

3. 排查的另一问题：当前帧预测是否依赖历史状态

排查结果：存在跨帧前向时序依赖。

- 当前帧预测依赖此前帧生成的 InstanceBank、InstanceQueue 历史特征缓存。
- 单独抽取一帧冷启动计算，可能与连续处理时的预测和 Loss 不同，需要顺序重放历史帧。
- 历史缓存经过 `detach()`，历史帧的计算图已切断。

因此，**当前帧预测依赖历史特征，但梯度不会通过历史缓存向历史帧反向传播。**

4. 初步解决方案：五域概率映射校正

定义 Actor 输出概率 $\boldsymbol{p}$，长期预期实际训练帧比例 $\boldsymbol{r}$，建立线性映射：

$$\boxed{\boldsymbol{r} = M\boldsymbol{p}}$$

其中 M 是由 1400 条序列的长度及五域组成确定的 5×5 矩阵：

$$M_{dk} = \frac{1}{N_k}\sum_{s=1}^{1400}\frac{n_{sd}n_{sk}}{L_s}$$

N_k 为域 k 的总帧数，n_{sd} 为序列 s 的域 d 帧数。

给定 Actor 目标 $\boldsymbol{p}$，求解校正后的五域采样控制概率：

$$\boxed{\boldsymbol{q}^* = \arg\min_{\boldsymbol{q}\in\Delta_4}\|M\boldsymbol{q}-\boldsymbol{p}\|_2^2}$$

$$\Delta_4 = \left\{\boldsymbol{q}\in\mathbb{R}^5 : q_k \geq 0,\ \sum_{k=1}^{5} q_k = 1\right\}$$

将 $\boldsymbol{q}^*$ 输入原有序列采样器，使实际帧比例尽量接近 Actor 目标。映射矩阵预计算一次，校正概率每次 Actor 更新时重新求解。

三、阶段二：概率校正实验与奖励机制修正

1. 概率校正后的正式训练结果

实验	L2 ↓ (m)	碰撞率 ↓	PDMS ↑
五域基线	**0.574639**	0.075427%	**88.5763**
原 L2-MoS	0.601036	**0.058605%**	88.5037
概率校正版	0.603373	0.074884%	88.5477

实验时间：训练约 9 小时 22 分；原记录标注评测完成于 11 月 7 日 04:22。

相较原 L2-MoS，PDMS 略升，但 L2 和碰撞率变差；相较五域基线，L2 和 PDMS 均未改善。

概率校正效果：

实验	转向域目标	实际曝光	偏差
原 L2-MoS	10.45%	8.12%	2.33 pp
概率校正版	10.85%	10.78%	0.06 pp

五域全程平均绝对偏差由 **1.38 pp 降至 0.054 pp**。

说明概率执行精度显著提高，但未带来驾驶指标的全面改善。

2. 发现的问题一：L2 奖励与 Actor 优化目标不匹配

实验现象：

- 出现 63 次域内 L2 恶化，其中 42 次对应域采样概率仍上升。
- 离线回放将每轮五域奖励改为相同值后，仍有 4/5 个域的最终调整方向与真实训练一致。

原有奖励计算：

$$\Delta_d = L2_d^{\text{prev}} - L2_d^{\text{curr}}$$

$$r_d = \exp\left(\text{clip}\left(\frac{\Delta_d}{0.1}, -2, 2\right)\right)$$

原 Actor 损失：

$$\mathcal{L}_{\text{Actor}} = -\sum_d r_d \log p_d$$

固定奖励下，最优目标比例为：

$$\boxed{p_d^* = \frac{r_d}{\sum_j r_j}}$$

关键问题：当前优化目标隐含均匀配比基准，而不是当前采样比例。

- 五域奖励相同时，目标为每域 20%，而非保持当前比例。
- 即使某域奖励较小，只要当前比例低于归一化奖励对应的目标，Actor 仍倾向于增加该域比例。

例如，加速域当前为 1%，L2 恶化 0.01 m：

$$r_{\text{acc}} = e^{-0.01/0.1} \approx 0.905$$

若其他四域奖励均为 1，则：

$$p_{\text{acc}}^* = \frac{0.905}{4 + 0.905} \approx 18.45\%$$

虽然该域恶化，但优化目标仍远高于当前的 1%。

3. 问题一的处理：基于当前比例进行相对奖励更新

保留原 L2 奖励和 EMA 平滑，记平滑奖励为 $\bar{r}_d$。

将目标改为：

$$\boxed{p_d^{\text{target}} = \frac{p_d^{\text{old}} \bar{r}_d}{\sum_j p_j^{\text{old}} \bar{r}_j}}$$

Actor 新损失：

$$\boxed{\mathcal{L}_{\text{Actor}} = -\sum_d p_d^{\text{target}} \log p_d}$$

新规则：

- 奖励高于当前概率加权的平均奖励：提高目标比例。

- 奖励低于该平均值：降低目标比例。
- 所有域奖励相同：保持原有配比。

例如，某域当前为 1%，其他四域奖励均为 1：

该域奖励	新目标概率	调整方向
2	1.98%	增加
1	1.00%	不变
0.5	0.50%	减少

实现时固定一轮 Actor 更新的旧概率和目标概率；五域奖励完全相同时跳过 Actor 更新，避免优化器历史动量产生无意义漂移。

4. 发现的问题二：固定奖励样本的代表性与稳定性不足

原方案每个域固定 64 个训练目标，每 200 次模型更新测量一次 L2，以前后变化生成奖励。

（1）样本代表性风险

对比原 L2-MoS 和概率校正版的低速域：

测量范围	原 L2-MoS	概率校正版	恶化幅度
固定 64 个训练目标	0.2757 m	0.2806 m	0.0049 m
验证集 975 个低速目标	0.3818 m	0.4365 m	**0.0547 m**

固定样本上的差异远小于完整验证域上的差异。两次实验的测量时点和样本不同，因此不能仅凭此表确定因果关系。

（2）奖励方向敏感

29 次策略更新 × 5 域，共 145 次域级改善判断。

其中 **37 次（25.5%）**，仅删除 64 个目标中的一个特定样本，就会使域平均 L2 改善量改变正负号。

5. 问题二的处理：动态轮换奖励样本

每轮在各域随机选择 64 个目标，五域共 320 个；下一轮重新抽取。

选择样本集 A，测量训练前 L2

⇓

训练 200 次模型更新

⇓

在 A 上测量训练后 L2，计算奖励并更新 Actor

⇓

选择样本集 B，测量新的训练前 L2，继续下一轮

同一轮前后必须使用同一批目标，避免将样本差异误判为模型性能变化。目标测量仍按原方式重放历史前缀。

该方法扩大了长期样本覆盖，但增加奖励测量开销，也不能直接消除单轮 64 个样本的统计波动。

6. 机制修正版正式训练结果

这轮保留已有概率校正，只新增上述两项修改：**Actor 相对奖励更新 + 奖励样本轮换**。

实验	L2 ↓ (m)	碰撞率 ↓	PDMS ↑
五域基线	**0.5746**	0.0754%	88.5763
原始 MoS	0.6089	0.1172%	88.7599
原始 L2-MoS	0.6010	**0.0586%**	88.5037
概率校正版	0.6034	0.0749%	88.5477
机制修正版	0.6220	0.0939%	**89.3110**

相较概率校正版，PDMS 提高约 **0.7633 分**，但 L2 和碰撞率同时恶化。

机制修正版的 PDMS 超过五域基线约 0.7347 分，但三项指标仍未全部优于基线。

四、阶段三：机制修正版暴露出的两个采样控制问题

1. 问题一：采样概率变化过于剧烈

本轮低速/停驻域的实际曝光比例：

模型更新区间	曝光比例
0-1600	7.19%
1600-4000	52.92%
4000-5860	5.01%

29 次策略更新中：

- **12 次**单域概率变化超过 10 pp。
- 最大单域变化达到 **50.42 pp**。
- 某轮将低速/停驻目标概率从 33.9% 直接提高至 84.3%。

原因：

第一，指数奖励放大 L2 改善差异：

$$r = \exp(\Delta L2/0.1)$$

例如：

L2 变化	奖励
改善 0.1 m	2.718
无变化	1
恶化 0.1 m	0.368

改善和恶化 0.1 m 时的奖励相差约 7.39 倍。

第二，实际 EMA 采用：

$$\bar{r}_t = 0.9r_t + 0.1\bar{r}_{t-1}$$

当前奖励占 90%，对短期变化的平滑较弱。

第三，Actor 算出目标后直接向其调整，缺少独立的单次变化幅度限制。

初步处理：增加 20% 概率平滑。

$$\boxed{\boldsymbol{p}_{t+1} = 0.8\boldsymbol{p}_t + 0.2\boldsymbol{p}_t^{\text{feasible}}}$$

例如：

$$0.8 \times 33.9\% + 0.2 \times 84.3\% = 43.98\%$$

本轮只调至 43.98%，下一轮再根据反馈继续调整。

该方案旨在降低跳变，但对最终驾驶性能的贡献尚未通过独立训练验证。

2. 问题二：概率校正仍受可实现范围限制

原校正器控制五域入口概率，无法自由控制所有序列的抽取次数。

29 次更新中，**25 次 Actor 原始请求超出当前映射的可行范围**，最大单域校正偏差为 **10.17 pp**。

例如，某轮减速域请求从 4.27% 提高至 9.75%，可行性校正后该域实际目标反而为 0.56%。

离线检查：

检查结果	次数
请求原本可行	4
原请求不可行，缩小到原幅度的 20% 后可行	7
缩小到原幅度的 1% 仍不可行	18

25 次不可行请求中，10 次单域调整超过 10 pp，另有 15 次不超过 10 pp。

因此，**不可行不只是调整幅度过大，还与完整混域序列构成的可行范围有关。**

举例：两类序列均为 10 帧。

序列	直行	减速	减速占比
A	8 帧	2 帧	20%
B	6 帧	4 帧	40%

- 希望减速占 30%：A、B 各抽一半，可以实现。
- 希望减速占 60%：全部抽 B 也只能实现 40%，无法实现。

当前校正后可行比例与真实训练曝光之间，五域全程平均偏差约 0.10 pp。这说明原校正器对**可行目标**执行得较准确，但不代表 Actor 的任意目标均可实现。

这一发现引出了后续五轮序列级采样离线实验。

五、五轮离线验证：序列级采样优化

五次离线验证均以 1400 条序列和历史 29 次 Actor 更新目标为基础，重点检查采样机制的可实现性、比例精度、集中程度和短窗口训练覆盖。离线回放不涉及模型重新训练。

第一次离线验证：直接优化 1400 条序列的抽样概率

1. 方案设计

原方案控制五个域入口的概率，新方案直接根据全部序列的五域组成，优化各条序列的帧贡献权重。

定义序列 s 的五域组成：

$$\boldsymbol{v}_s = \left(\frac{n_{s1}}{L_s}, \ldots, \frac{n_{s5}}{L_s}\right)$$

令 w_s 为序列 s 对长期总训练帧数的期望贡献比例，Actor 的五域目标为 $\boldsymbol{p}$。

求解：

$$\min_{\boldsymbol{w}} \quad \left\| \sum_{s=1}^{1400} w_s \boldsymbol{v}_s - \boldsymbol{p} \right\|_2^2$$
$$\text{s.t.} \quad w_s \geq 0, \quad \sum_{s=1}^{1400} w_s = 1$$

将帧贡献权重换算为真正的序列抽样概率。

设 q_s 为抽中完整序列 s 的概率。长期抽取 K 次序列，其预期贡献帧数为 Kq_sL_s。

因此：

$$w_s = \frac{Kq_sL_s}{\sum_j Kq_jL_j} = \frac{q_sL_s}{\sum_j q_jL_j}$$

两边除以 L_s 并对所有序列求和：

$$\sum_s \frac{w_s}{L_s} = \frac{\sum_s q_s}{\sum_j q_jL_j} = \frac{1}{\sum_j q_jL_j}$$

得到：

$$q_s = \frac{w_s / L_s}{\sum_j w_j / L_j}$$

这一换算确保**变长序列的抽段概率与期望训练帧贡献相一致**。

2. 第一次离线实验结果

指标	旧五域校正	新序列级优化（无平滑）	指标解释
历史目标可实现次数	4/29	**29/29**	29 次历史目标中能精确实现的次数，衡量采样器的控制范围。
最大单域理论比例偏差	10.17 pp	**接近 0**	所有轮次中最严重的单域目标偏差，越小表示理论配比精度越高。
200 步窗口模拟曝光平均误差	1.37 pp	**0.62 pp**	消费模拟中实际曝光与原始 Actor 目标的平均偏差，越小表示短窗口执行越准确。
最高单序列抽样概率	0.74%	11.45%	任一轮单条序列被抽中的最高概率，反映极端重复采样风险。
前 20 条序列最高概率合计	8.30%	40.01%	某轮概率最高的 20 条序列合计占比，反映头部采样集中程度。

其中短窗口曝光结果基于 128 次序列消费模拟，各项最大值可能出现在不同轮次。

比例精度确实得到提高：

- 理论可实现次数从 4/29 提高至 **29/29**，最大单域理论偏差从 10.17 pp 降至接近 0。
- 每 200 次更新窗口的模拟曝光平均误差从 1.37 pp 降至 **0.62 pp**，减少 0.75 pp，降幅约 **54.7%**。

这表明新序列级优化不仅扩大了目标比例的可实现范围，也使短窗口模拟曝光更接近 Actor 的原始目标。

3. 发现的问题：比例精度提高，但序列抽样严重集中

第 3200 次模型更新后：

- 一条仅 17 帧的序列获得 11.45% 的抽样概率。
- 按随后 200 次模型更新的训练预算估算，预计重复抽取约 **64 次**。

另外，无平滑条件下最大单域目标跳变达到 51.59 pp。

对序列帧贡献权重加入 20% 平滑：

$$w_{t+1} = 0.8 w_t + 0.2 w_t^*$$

指标	无平滑	20% 平滑
最大单域概率跳变	51.59 pp	**13.04 pp**
最高单段抽样概率	11.45%	**3.37%**

考虑正在消费的旧序列与预取后，新旧方法均能在约 15 次模型更新内完成策略切换。

第一次验证确认：直接控制 1400 条序列扩大了域比例的可实现范围，提高了比例执行精度，但严格追求比例精度会带来明显的采样集中风险。

第二次离线验证：比例精度与采样多样性的权衡

1. 实验目的与优化模型

研究能否通过允许少量域比例偏差，让序列采样分布更接近原始参考分布。

$$\begin{aligned} \min_{\boldsymbol{w}} \quad & D_{\mathrm{KL}}(\boldsymbol{w} \| \boldsymbol{w}_{\mathrm{ref}}) \\ \text{s.t.} \quad & \left\| \sum_{s=1}^{1400} w_s \boldsymbol{v}_s - \boldsymbol{p} \right\|_{\infty} \le \varepsilon \\ & w_s \ge 0, \quad \sum_s w_s = 1 \end{aligned}$$

其中：

- $\boldsymbol{w}_{\mathrm{ref}}$：冻结的初始化参考帧贡献分布。
- ε：允许的最大单域比例偏差。
- D_{KL}：KL 散度，用来衡量新分布相对于参考分布的差异。

KL 散度（Kullback-Leibler Divergence）定义为：

$$D_{\mathrm{KL}}(\boldsymbol{w} \| \boldsymbol{w}_{\mathrm{ref}}) = \sum_{s=1}^{1400} w_s \log \frac{w_s}{w_{\mathrm{ref},s}}$$

当两分布相同时，KL 为 0；差异越大，KL 越大。

目标是：在允许的配比误差范围内，使帧贡献分布尽可能接近参考分布。

约束中的无穷范数：

$$\left\| \sum_s w_s \boldsymbol{v}_s - \boldsymbol{p} \right\|_{\infty} = \max_d \left| \sum_s w_s v_{s,d} - p_d \right|$$

控制的是五个域中**最大的单域绝对比例偏差**。

2. 实验设置与结果

扫描：

$$\varepsilon \in \{0,\ 0.25,\ 0.5,\ 1,\ 2\}\ \text{pp}$$

29 次历史目标 × 5 组误差阈值，共 145 次优化，全部通过数值核验；未加入平滑。

允许偏差	最高单段概率均值	最差单段概率	最差前 20 段概率合计	最低有效序列数
0 pp	1.40%	11.45%	40.01%	34.6
0.25 pp	1.21%	10.81%	39.15%	44.1
0.5 pp	1.09%	10.16%	38.31%	46.8
1 pp	0.89%	9.50%	36.74%	51.9
2 pp	**0.68%**	**8.27%**	**33.63%**	**64.1**

各指标解释：

指标	含义
最高单段概率均值	29 轮中每轮最大单段概率的平均，衡量平均极端集中程度。
最差单段概率	全部历史轮次出现的最高单段抽样概率，用于发现最严重的单序列重复风险。
最差前 20 段概率合计	各轮前 20 条最高概率之和的最大值，衡量最差轮次的头部集中程度。
最低有效序列数	以 $1/\sum_s q_s^2$ 衡量抽样分散程度，最小值越低表示最差轮次越集中。

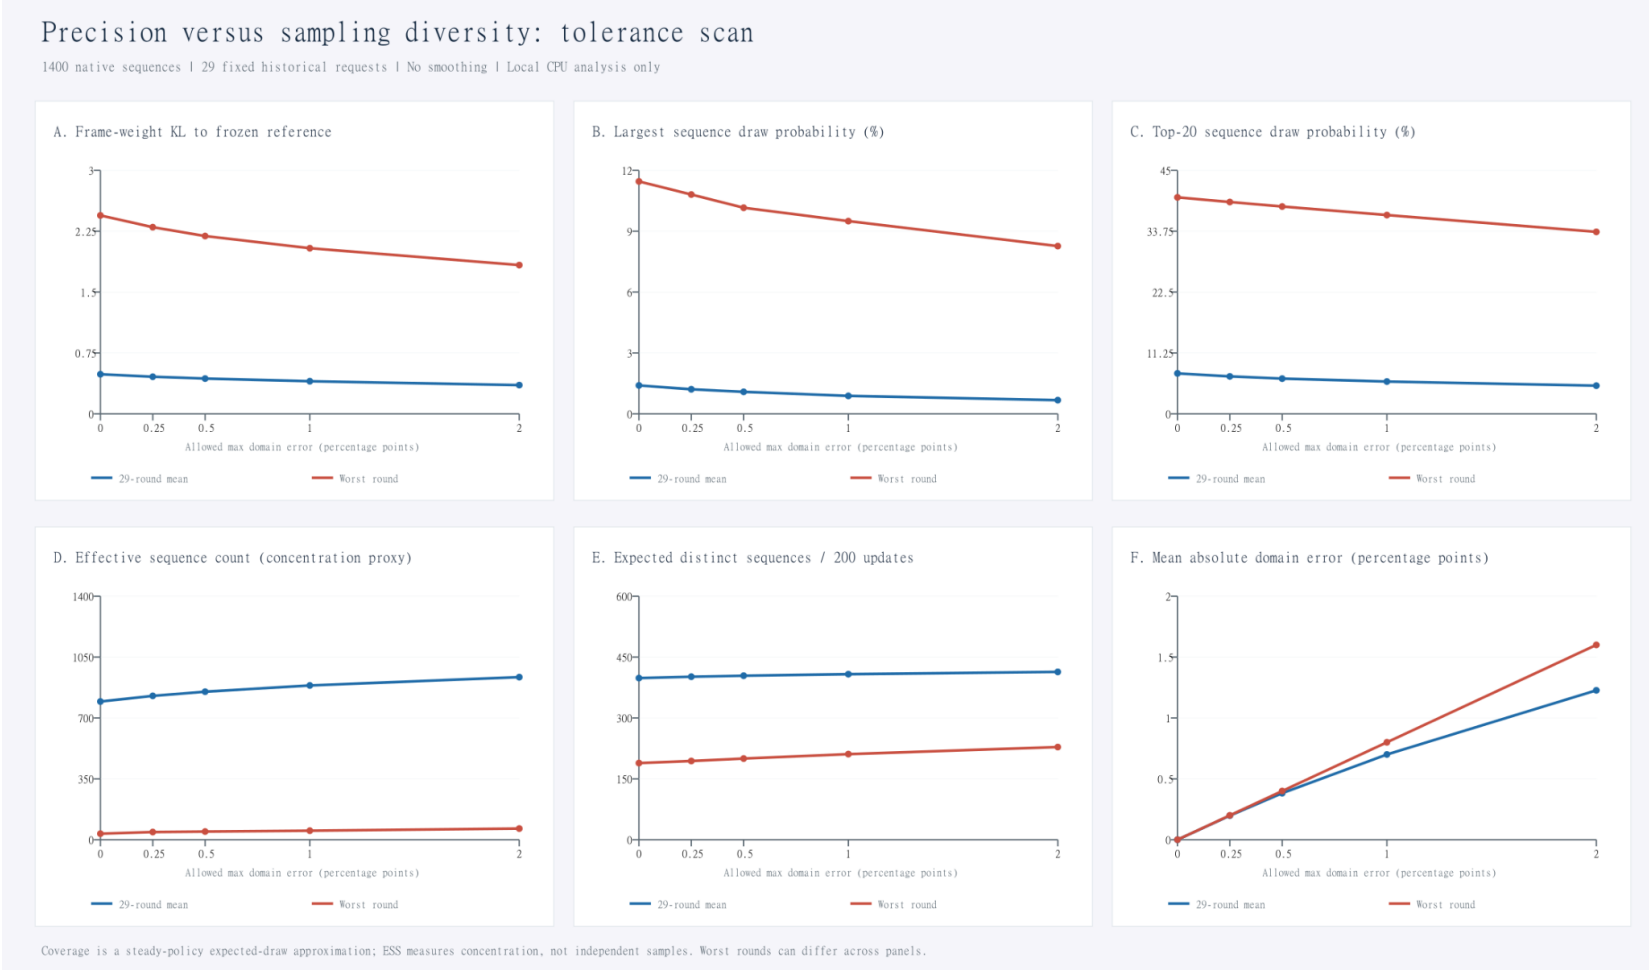
最高单段概率均值为 29 轮中每轮最大值的平均；各极值可能来自不同轮次。

3. 完整实验曲线

原始六联图见下页独立横向大图，六图分别为：

图	指标	检查目的
A	KL 散度	新分布是否更接近参考分布
B	最大单段抽样概率	是否缓解极端单序列集中
C	前 20 段概率合计	头部序列是否仍占据过多权重
D	有效序列数	抽样概率整体是否分散
E	每 200 次更新的预期覆盖数	短窗口能够覆盖多少不同序列
F	五域平均绝对比例偏差	放宽精度造成多少控制误差

第二次离线验证：比例精度与采样多样性的六项指标曲线



原始六联图。蓝线为 29 轮均值，红线为最差轮次；D 中有效序列数为 $N_{\text{eff}} = 1/\sum_s q_s^2$，F 为五域平均绝对比例误差。

4. 主要发现

（1）平均集中程度下降，但最差轮次改善不足。

允许 2 pp 误差后，最差单段概率仍达 8.27%。

第 3200、3400 次更新仍是突出问题：

更新位置	允许 2 pp 后的最大单段概率
3200	8.27%
3400	5.83%

（2）覆盖改善有限。

每 200 次更新预期覆盖	0 pp	2 pp
29 轮平均	约 398 条	约 413 条
最差轮次	189 条	228 条

（3）统一绝对误差阈值可能严重影响小域。

第 3400 次更新，加速域原始目标仅 0.111%，允许 1 pp 偏差后，优化结果为 1.054%，达到原目标约 **9.5 倍**。

第二次验证结论：适度允许域比例偏差能改善分布，但在 0～2 pp 范围内，仍无法充分解决最差轮次的采样集中。

第三次离线验证：单序列抽样概率上限

1. 优化方案

为了直接限制单序列重复采样，引入：

$$\boxed{q_s \le q_{\max}, \quad \forall s}$$

根据：

$$q_s = \frac{w_s/L_s}{\sum_j w_j/L_j}$$

该约束等价于：

$$\boxed{\frac{w_s}{L_s} \le q_{\max} \sum_j \frac{w_j}{L_j}}$$

这是关于帧贡献权重 $\boldsymbol{w}$ 的线性约束，可以直接加入优化问题。

在该限制下，先最小化五域比例平方误差：

$$\boxed{\begin{aligned} \min_{\boldsymbol{w}} \quad & \left\| \sum_s w_s \boldsymbol{v}_s - \boldsymbol{p} \right\|_2^2 \\ \text{s.t.} \quad & w_s \ge 0, \quad \sum_s w_s = 1 \\ & \frac{w_s}{L_s} \le q_{\max} \sum_j \frac{w_j}{L_j}, \quad \forall s \end{aligned}}$$

再在最优比例误差下尽量保持参考采样分布。

2. 实验设置与结果

扫描：

$$q_{\max} \in \{0.75\%, 1\%, 2\%, 3\%\}$$

116 组结果均通过独立核验，未加入平滑。

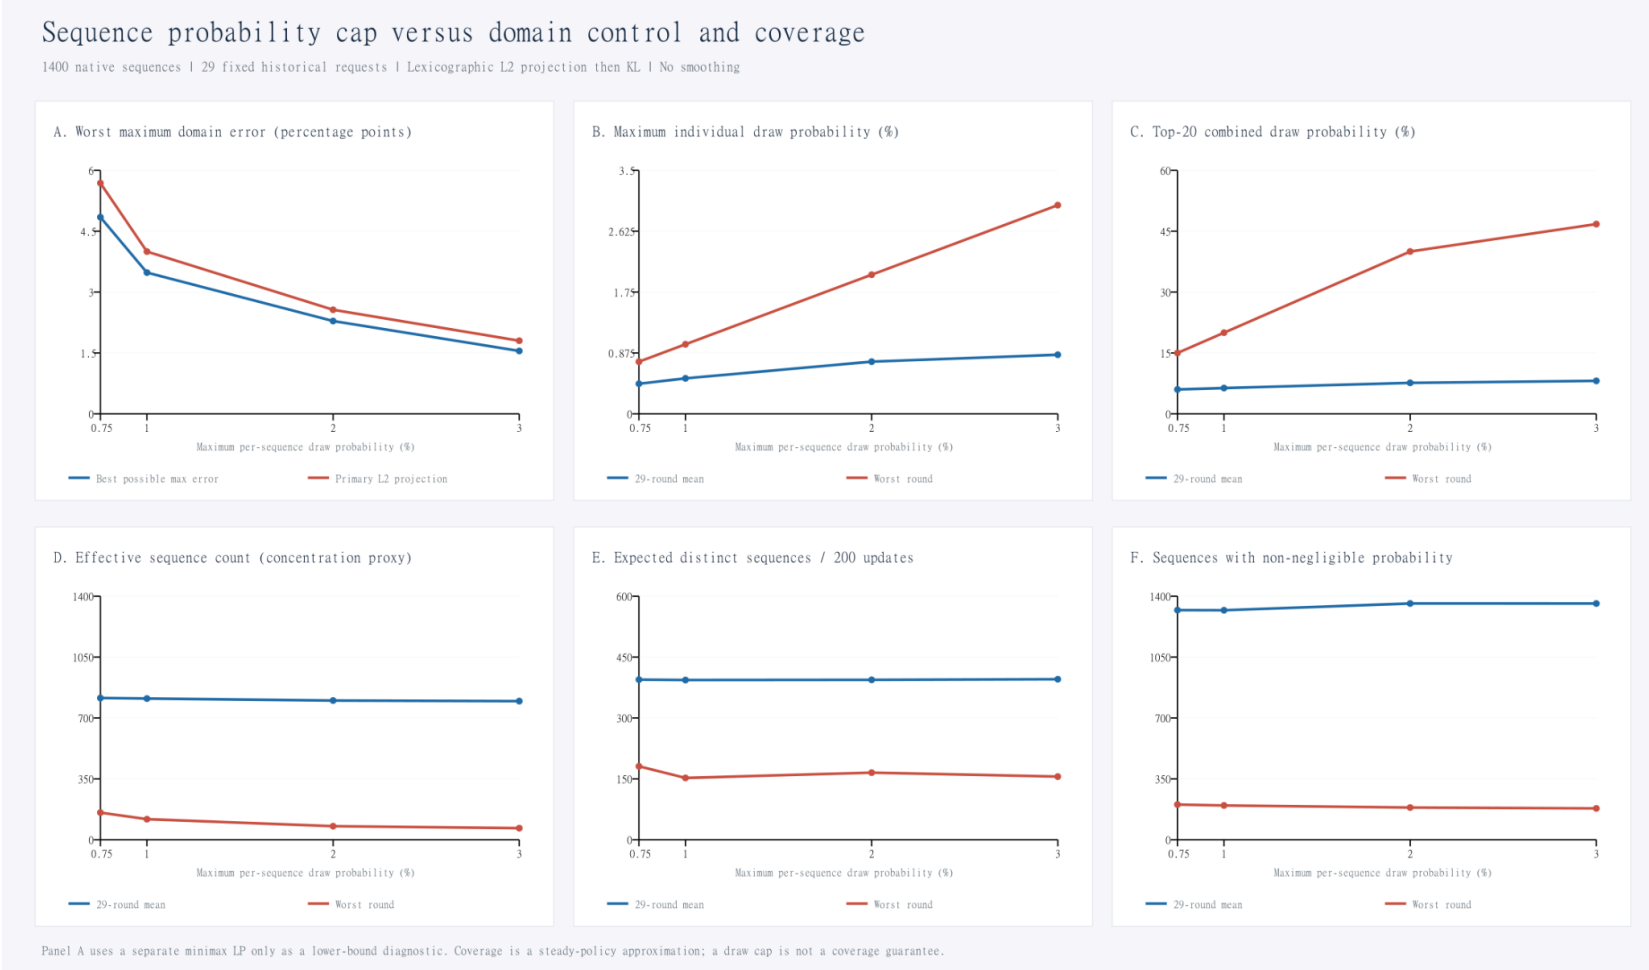
单段概率上限	可精确实现的目标	最大单域偏差
0.75%	27/29	5.69 pp
1%	27/29	4.00 pp
2%	28/29	2.56 pp
3%	28/29	1.80 pp

各指标解释：

指标	含义
可精确实现的目标	29 次历史目标中，在指定单段概率上限下仍可实现零域比例误差的次数。
最大单域偏差	五域平方误差最优解在历史轮次中的最大单域比例偏差，用于衡量概率上限带来的控制精度损失。

这里的最大单域偏差来自以**五域平方误差最小**为目标的求解，不是最小最大偏差的理论下界。

第三次离线验证：单序列抽样概率上限与领域控制精度



原始六联图。A 中蓝线为单独最小化最大单域偏差得到的理论下界，红线为平方误差优化结果；B～F 展示均值及最差轮次。

3. 完整实验曲线

原始六联图见前页独立横向大图。图中 A 检查控制精度，B 检查单段上限是否执行，C 检查头部集中，D 检查有效序列数，E 检查短窗口覆盖，F 检查仍获得非微小概率的序列数量。

4. 主要发现

（1）1% 单段上限使两个历史目标无法精确实现。

第 3200、3400 次更新的目标，在 1% 上限下不可精确实现。

进一步单独最小化最大单域偏差：

更新位置	最小可能的最大单域偏差
3200	3.24 pp
3400	3.48 pp

因此，对这两个目标而言，单段上限 1% 与所有域偏差不超过 1～2 pp 无法同时满足。

（2）单段上限不能保证整体数据覆盖。

第 3200 次更新：

方案	每 200 次更新预期覆盖
无上限、严格匹配	约 269 条
1% 上限、最小比例误差	**约 152 条**

此时 **81 条序列同时达到 1% 上限，合计占据 81% 的抽段概率**。

说明虽然避免了单条序列拥有 11.45% 的高概率，但权重仍可能集中在一批序列上。

第三次验证结论：单段概率上限能够限制极端单序列抽样，但不能独立保证整体训练覆盖。

第四次离线验证：概率平滑与额外比例误差余量

1. 实验目的

第三次验证发现，1% 单段概率上限虽然限制了单条序列的最高概率，但 81 条序列仍可能共同占据 81% 的抽样概率。

本次分别测试：

- **实验 A**：20% 平滑是否能够改善短窗口覆盖。
- **实验 B**：在最优比例误差基础上允许额外偏差，是否能够减少整体采样集中。

2. 实验 A：20% 概率平滑

采用：

$$\boxed{\boldsymbol{w}_{t+1}^{\text{installed}} = 0.8\boldsymbol{w}_{t}^{\text{installed}} + 0.2\boldsymbol{w}_{t+1}^{*}}$$

固定单段概率上限为 1%，按照历史 29 次目标顺序回放，并进行每窗口 128 次序列消费模拟。

实验结果：

模型更新位置	不平滑覆盖	20% 平滑覆盖
3200	179 条	**421 条**
3400	199 条	**396 条**

第 3200 次更新，前 81 条序列的合计抽样概率由 **81% 降至 24.85%**。

但跟随 Actor 目标出现明显滞后：

比较对象	五域平均绝对偏差
模拟曝光与已安装比例	0.67 pp
模拟曝光与原始 Actor 目标	**7.97 pp**

结果：平滑显著改善短窗口覆盖，但大幅减慢了对 Actor 目标变化的响应。若目标持续不变，平滑分布仍可能逐渐接近原先的集中目标。

3. 实验 B：允许额外比例误差

固定：

$$q_{\max} = 1\%$$

首先在单段概率上限下，求解最小可能的最大单域偏差：

$$\boxed{\delta^{*} = \min_{\boldsymbol{w} \in \mathcal{W}_{\text{cap}}} \left\| V^{\top}\boldsymbol{w} - \boldsymbol{p} \right\|_{\infty}}$$

其中，$\mathcal{W}_{\text{cap}}$ 表示满足概率非负、归一化和单段 1% 上限的可行集合。

然后额外允许 η 个百分点的偏差：

$$\begin{aligned} \min_{\boldsymbol{w}} \quad & D_{\mathrm{KL}}(\boldsymbol{w} \| \boldsymbol{w}_{\mathrm{ref}}) \\ \text{s.t.} \quad & \| V^{\top}\boldsymbol{w} - \boldsymbol{p} \|_{\infty} \le \delta^{*} + \eta \\ & \boldsymbol{w} \in \mathcal{W}_{\mathrm{cap}} \end{aligned}$$

这里：

- δ^{*}：在 1% 单段上限下无法避免的最小最大域偏差。
- η：在这一最优偏差基础上额外允许的误差。
- KL 散度：用于尽量维持参考帧贡献分布。

扫描：

$$\eta \in \{0,\ 0.5,\ 1,\ 2\}\ \mathrm{pp}$$

实验结果：

额外余量 η	最差窗口模拟覆盖	3200 处前 81 段概率合计	全历史最大单域偏差
0 pp	183 条	81.00%	3.48 pp
0.5 pp	247 条	64.34%	3.98 pp
1 pp	261 条	58.41%	4.48 pp
2 pp	**283 条**	**50.25%**	5.48 pp

各指标解释：

指标	含义
最差窗口模拟覆盖	历史窗口中模拟实际抽取到的不同序列数的最低值，衡量最差短窗口的数据覆盖。
3200 处前 81 段概率合计	第 3200 次更新时抽样概率最高的 81 条序列的合计概率，衡量极端轮次的整体集中程度。
全历史最大单域偏差	29 次历史目标中安装比例与 Actor 原始目标之间最大的单域绝对偏差，衡量控制精度损失。

主要发现：

- 额外允许 **0.5 pp** 偏差，最差窗口覆盖从 183 条增加到 247 条，提升约 **35%**。
- 允许 2 pp 后，前 81 条序列仍占据 50.25% 的概率。
- 额外误差余量能够改善覆盖，但不能完全消除集中。

注意：这里的 $\eta = 1$ pp 是在 δ^{*} 基础上额外允许 1 pp，不代表总误差小于 1 pp。

4. 两种方法联合测试

将 1% 单段上限、0.5～1 pp 额外余量与 20% 平滑组合：

指标	联合方案
单段概率上限	1%
额外误差余量	0.5～1 pp
平滑系数	20%
最差窗口模拟覆盖	**408～413 条**
对原始 Actor 目标的平均偏差	约 8 pp

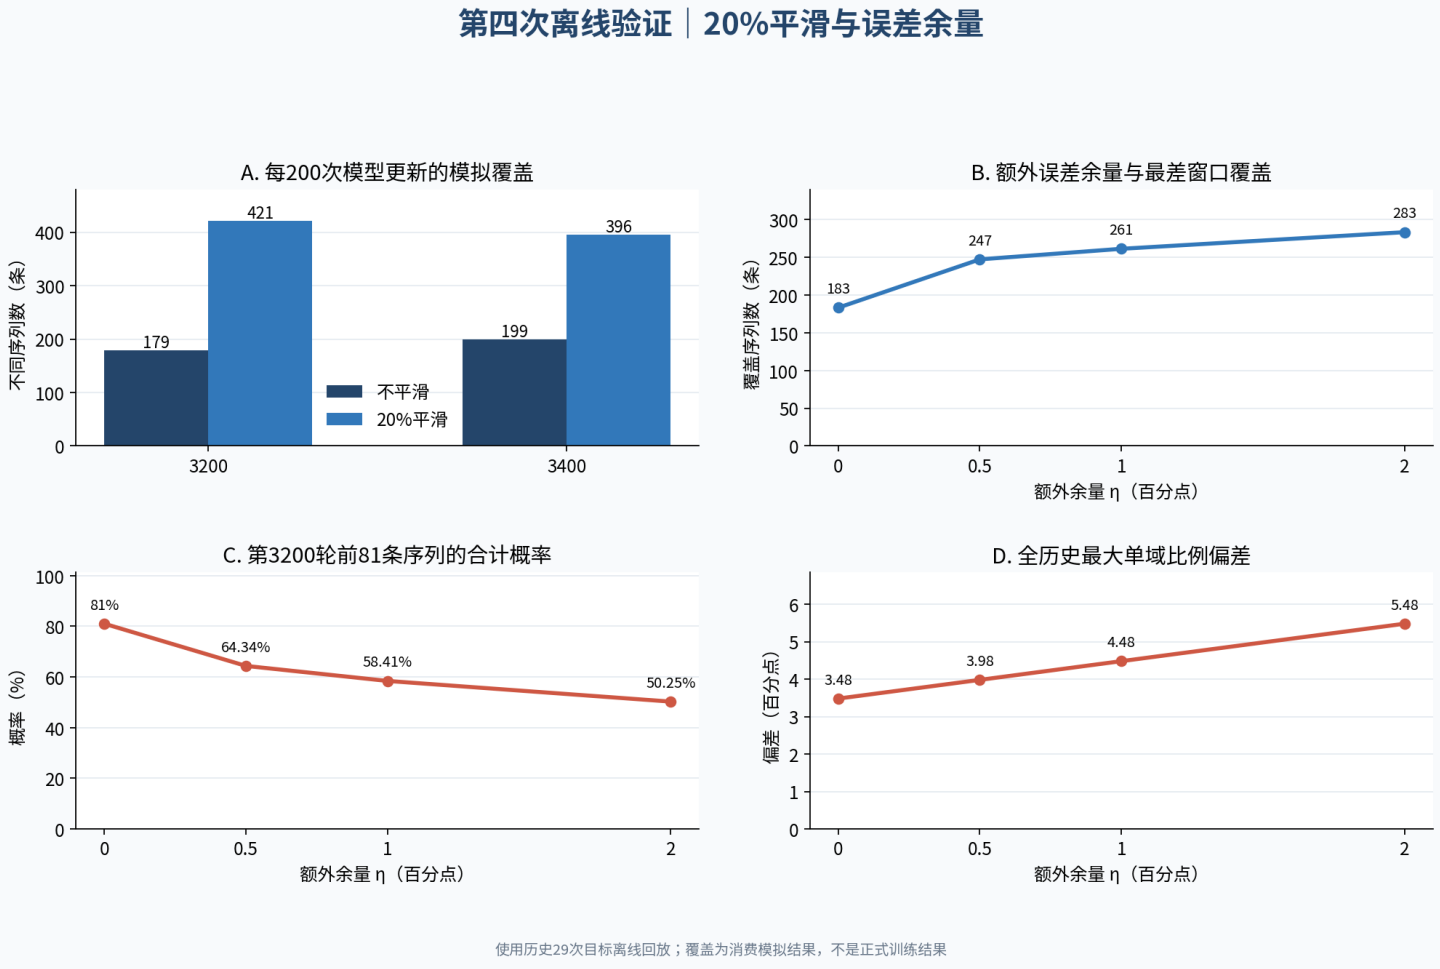
联合方案改善了短窗口覆盖，但对 Actor 原始目标的跟随程度下降。

第四次验证结论：平滑改善稳定性但引入响应滞后；额外允许比例误差改善覆盖但牺牲控制精度。两者联合仍存在明显取舍。

5. 实验图表

下页为根据已确认数值重绘的对照图，并非原始逐轮曲线文件。

第四次离线验证：平滑与额外比例误差余量



根据已确认的实验数据重绘。A：平滑前后覆盖对比；B：额外余量与最差窗口覆盖；C：第 3200 轮前 81 段合计概率；D：最大单域比例偏差。

第五次离线验证：域比例双侧约束与最终方案筛选

1. 实验目的

前四次验证表明：

- 单次平滑能抑制跳变，但可能响应过慢。
- 单次变化限幅能控制更新速度，但不能阻止多个轮次逐渐走向极端比例。
- 单段概率上限和误差余量也无法独立保证长期覆盖。

本次通过限制最终域比例相对初始化参考分布的偏离范围，完成最后一轮采样机制筛选。

2. 域比例双侧约束

$$\boxed{\frac{p_d^{\mathrm{ref}}}{\rho} \le p_d^{\mathrm{installed}} \le \min(1, \rho p_d^{\mathrm{ref}})}$$

其中：

- p_d^{ref}：初始化时的实际期望帧比例。
- $p_d^{\mathrm{installed}}$：最终安装的五域期望帧比例。
- ρ：允许相对参考比例放大或缩小的倍数。

双侧约束既限制某域被过度提高，也防止某域被压低至接近零。

例如 $\rho = 3$，参考比例为 0.90% 的域，安装比例被限制在 0.30%～2.70%。

3. 两种候选调整机制

方案	更新机制	主要特点
A	无附加调整控制	响应充分，但集中明显
B	20% 平滑	覆盖较稳定，响应较慢
C	单域变化限幅 5 pp	保留更多调整空间，但可逐渐偏离参考分布
D	限幅 + 平滑	覆盖改善，但更新可能过于保守

最终重点筛选 B、C 两条路线。

共同设置：

$$q_{\max} = 1\%, \qquad \eta = 0.5 \text{ pp}$$

并扫描：

$$\rho \in \{2, 3, 4, 6\}$$

同时为 B、C 各保留一组无域范围约束的对照。

对于平滑方案：

$$\boldsymbol{w}_t^{\mathrm{installed}} = (1-\beta)\boldsymbol{w}_{t-1}^{\mathrm{installed}} + \beta \boldsymbol{w}_t, \qquad \beta = 0.2$$

最终安装的五域比例为：

$$\boldsymbol{p}_t^{\text{installed}} = V^\top \boldsymbol{w}_t^{\text{installed}}$$

域比例约束作用于**最终安装分布**，并在新增约束下重新计算最小可实现偏差，而非仅对 Actor 原始请求裁剪。

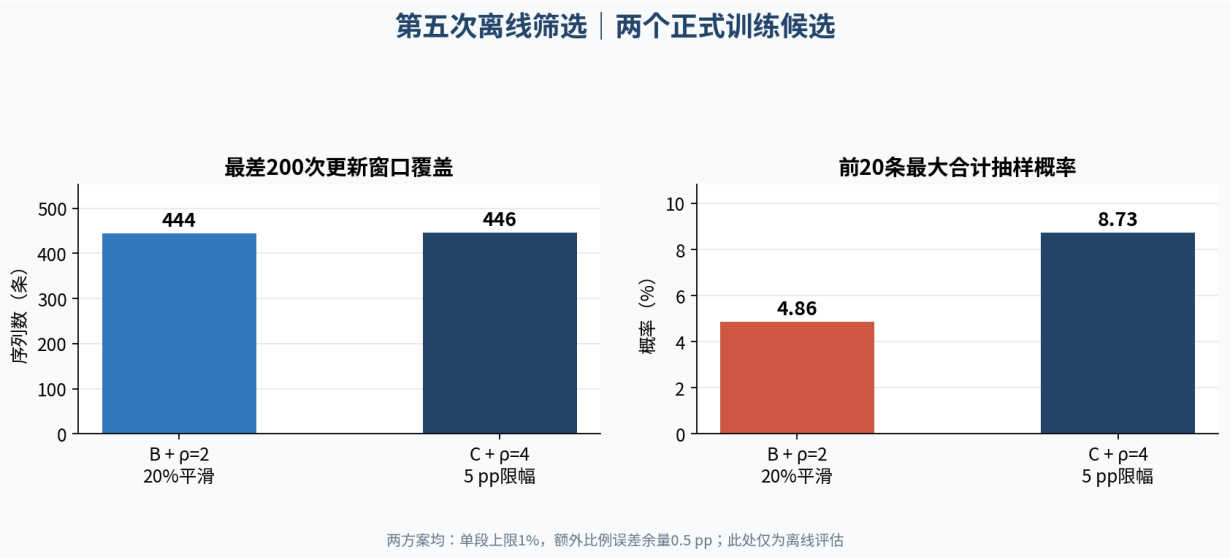
4. 实验设置与结果

共 **10 组配置 × 29 次历史更新 = 290 组回放**，包含消费模拟、数值核验和图表检查。

最终选出两个正式训练候选：

指标	B + ρ = 2	C + ρ = 4
概率调整方法	20% 平滑	单域变化限幅 5 pp
域比例范围	参考比例的 0.5～2 倍	参考比例的 0.25～4 倍
单段概率上限	1%	1%
额外误差余量	0.5 pp	0.5 pp
最差窗口覆盖	**约 444 条**	**约 446 条**
前 20 条最大概率合计	**4.86%**	8.73%

5. 候选方案对比图



依据离线筛选结果重绘，比较覆盖率与头部采样集中程度。

B + ρ = 2：约束更严格、头部集中度更低，偏向保留训练覆盖和稳定性。

C + ρ = 4：域比例调整范围更大，保留更多动态控制能力，但采样集中程度相对更高。

这两个候选并不是按驾驶性能排序，**目前没有正式训练证据证明哪一个更优**。

六、全部实验结果汇总

1. 五次真实模型训练结果

实验	L2↓(m)	碰撞率↓	PDMS↑
五域 DiffusionDrive 基线	**0.5746**	0.0754%	88.5763
原始 MoS	0.6089	0.1172%	88.7599
L2-MoS	0.6010	**0.0586%**	88.5037
L2-MoS 概率校正	0.6034	0.0749%	88.5477
L2-MoS 机制修正	0.6220	0.0939%	**89.3110**

目前真实训练显示，**没有一种 MoS 配置能够在 L2、碰撞率和 PDMS 三项指标上同时优于五域基线**。

2. 五轮离线验证结果总表

离线验证	核心改动	关键发现
第一次	直接优化 1400 条序列的采样概率	可实现性从 4/29 提高到 29/29，模拟曝光误差从 1.37 pp 降至 0.62 pp，但最高单段概率达 11.45%
第二次	放宽五域比例误差，KL 最小化	平均集中程度改善，但最差单段概率仍达 8.27%
第三次	单段概率上限 0.75%～3%	能限制单段概率，但 1% 上限下仍出现 81 条序列合计占 81% 的集中
第四次	20% 平滑与额外误差余量	覆盖改善，但产生目标响应滞后与比例精度代价
第五次	双侧域比例约束，筛选 B/C	选出两种覆盖与动态调整能力不同的正式训练候选

3. 当前已确认的问题与处理情况

问题	已采取的处理	当前验证状态
Actor 目标与实际曝光不一致	五域概率校正	执行精度已通过真实训练记录验证
Actor 隐含均匀配比基准	基于当前概率的相对奖励目标	已实施，但收益无法单独归因
奖励固定样本代表性不足	每轮轮换 64 个目标	已实施，稳定性改善尚未单独验证
Actor 概率剧烈跳变	平滑或单次限幅	离线验证可控制变化幅度
旧采样器可实现范围受限	直接优化序列概率	离线证明控制范围扩大
严格匹配导致抽样集中	KL、误差余量、单段上限	能缓解，但无法单独彻底解决
Actor 长期偏向极端配比	双侧域比例约束	已离线筛选，待正式训练验证

七、本阶段完成的工作与下一步验证

1. 阶段性成果：完成采样执行层适配与离线筛选

本阶段围绕 MoS 的域级决策与 DiffusionDrive 的完整序列训练之间的粒度不匹配，建立了从 Actor 目标、序列抽样概率到实际帧曝光的可计算映射，并进一步验证其可实现范围、控制精度与采样覆盖之间的权衡。**目前已形成两套经离线筛选的采样方案，但尚未证明其能提升驾驶性能。**

下表汇总本阶段取得的**直接对照证据**；详细实验设置与逐轮结果见前文。

处理的问题	原有表现	修正后证据	验证结论与边界
域目标与帧曝光不一致	五域平均绝对偏差 1.38 pp	**0.054 pp**（原五域概率校正）	真实训练记录支持：原映射偏差已显著修正
旧五域入口的控制范围受限	29 次历史目标仅 4 次可精确实现	**29/29**（无约束序列级优化）	离线证明控制范围扩大；加入单段上限后不再保证全部精确实现
短窗口比例精度不足	200 步模拟曝光误差 1.37 pp	**0.62 pp**（无平滑序列级优化）	相对原始 Actor 目标的平均误差下降约 54.7%，属于消费模拟
单条及头部序列集中	最高单段 11.45%，前 20 段最高合计 40.01%	最终两候选单段均不超过 **1%**；前 20 段分别为 **4.86% / 8.73%**	极端集中明显缓解，但不等于全部域内场景获得充分覆盖
最差训练窗口覆盖不足	1% 单段上限、零额外余量时最差覆盖 183 条	两候选最差模拟覆盖约 **444 / 446 条**	覆盖改善来自联合约束及策略更新机制，不能归因于单个改动

注：上述数字来自不同阶段、明确标注的对照条件；“真实训练记录”“理论可实现性”与“离线消费模拟”应分别理解，不能混同为模型性能改善。

2. 已验证的范围与尚待回答的问题

现阶段能够确认：**原五域映射的执行偏差已修正，序列级控制范围已扩大，概率集中与窗口覆盖问题已有可行的离线缓解方案**。但配比精度、样本覆盖和策略响应速度不能无代价地同时最优；奖励样本代表性、Actor 目标本身是否合理，以及最终驾驶性能仍待检验。

已有真实训练中，机制修正版的 PDMS 为 **89.3110**（五域基线 **88.5763**），但其 L2 为 **0.6220 m**（基线 **0.5746 m**）、碰撞率为 **0.0939%**（基线 **0.0754%**）。因此，**目前不能认定 MoS 动态配比的模型性能已优于基线**。

3. 下一步：由离线执行验证转向真实训练收益验证

正式训练保留两套已筛选候选：**B** + $\rho = 2$（20% 平滑）与 **C** + $\rho = 4$（单域 5 pp 限幅）；均采用单段概率上限 1%、额外比例误差余量 0.5 pp 和双侧域比例约束。**正式训练适配、冒烟测试及新候选训练尚未完成。**

以**相同奖励和 Actor 更新机制的 L2-MoS 机制修正版**为主要对照，在尽量一致的模型初始化、数据、参数更新预算下进行实验，同时核对固定训练时间。重点检查两个层面：一是 Actor 原始目标、安装比例、实际曝光、序列覆盖和优化开销是否吻合离线预期；二是 PDMS、L2、碰撞率能否在固定训练时间下获得实际改善。五域基线及此前 MoS 版本仍作为总体参考。

若采样执行与覆盖在真实训练中得到改善，而驾驶指标仍未提升，应将后续研究重点转向**L2 奖励反馈可靠性和 SENNA 五域划分合理性**，而不是继续无限叠加采样器约束。

记录核对项：原始记录中 L2-MoS 首次评测标注为 11 月 9 日，概率校正版标注为 11 月 7 日，与按技术阶段排列的顺序不一致。正式归档时应以训练日志核实日期。